

突破 Coding Agent 能力天花板

基于 Context Graph 的记忆架构演进

WU Zihan

January 27, 2026

1. 业界现状：从“长窗口”到“结构化记忆”的演进

主流模型记忆机制 (State of the Art)

- ▶ 超长上下文 (**Brute Force**):
Gemini (1M+), Claude (200K)。
局限：被动且昂贵，无法跨会话累积。
- ▶ 向量 **RAG (Vector Database)**:
ChatGPT, Auto-GPT。基于语义相似度检索。
局限：**丢失结构与关系**（知道“A”和“B”相似，但不知“A 导致 B”）。
- ▶ 混合/隐式图谱:
Gemini “Personal Intelligence” (隐式关联用户数据)。

关键痛点：被动检索 vs 主动总结

传统 RAG 被动挖掘已有知识，无法主动抽象经验规律。
资深工程师的价值 = “踩过这个坑” + “总结了通用解法”。

LLM 需要主动记忆机制，而非每次重新检索。

技术新趋势：向有向图 (Directed Graph) 转化

趋势：Unstructured Vectors → Structured Graphs

- ▶ **Microsoft GraphRAG**: 利用社区检测 (Community Detection) 解决全局性问题。
- ▶ **Zep (Temporal KG)**: 引入“时序知识图谱”，记忆事实的演变。
- ▶ **LangGraph**: 用图 (StateGraph) 规划 Agent 的思考流/控制流。

核心判断：Coding 场景必须结合 **AST** (依赖图) + 执行流 (因果图)，结构化记忆是唯一解。

2. 核心方案：Context Graph 可生长记忆架构

方案本质：融合”数据图谱”与”控制流”的专用记忆体

借鉴 Zep (记忆存储) 与 LangGraph (流程控制) 理念，构建专用于 Coding 的 有向图谱。

架构设计：显式化”经验路径”

1. 节点 (Nodes) - 沉淀痕迹

- ▶ Action/State: 执行与反馈 (类似 LangGraph 状态)。
- ▶ Insight: 经验胶囊 (主动抽象的通用规则, 如”遇到 X 错误 → 修改 Y 配置”)。

2. 有向边 (Directed Edges) - 锁定逻辑

- ▶ NEXT (时序): 记录操作流, 复用成功路径。
- ▶ CAUSES (因果): 根因分析, 解决 Vector RAG 无法推理因果的缺陷。
- ▶ DEPENDS_ON: 代码静态依赖 (AST)。

差异化优势 (The Graph Advantage)

- ▶ 主动学习 vs 被动检索:
主动总结成功/失败模式, 形成可复用规则。被动 RAG 只能”找相似案例”。
- ▶ 知识迁移能力 (Zero-Shot):
图谱足够丰富时, 能通过路径推理解决未见过的问题 (如组合已知模式)。
- ▶ 数据飞轮:
任务越多 → 经验越丰富 → 解决新问题越快。

3. 实施路线与业务价值

落地路线图 (Roadmap)

1. **Phase 1: MVP (2-3 个月)** —— 主动学习闭环
 - ▶ 场景: SWE-bench Lite。
 - ▶ 目标: Agent **主动总结** 失败模式, 抽象为 Insight 节点, 不再重复犯错。
2. **Phase 2: 企业级适配 (4-6 个月)** —— 存量攻坚
 - ▶ 场景: C/C++ 大型遗留系统。
 - ▶ 技术: 引入 AST 代码依赖分析, 构建项目级图谱。
3. **Phase 3: 人机协同 (长期)** —— 知识迁移
 - ▶ **跨项目迁移**: 成熟图谱迁移到新项目, 零样本解决未见过的问题。
 - ▶ 吸纳人类工程师调试路径, 持续丰富图谱。

业务价值 (Value)

- ▶ 降本: 精准剪枝无效路径, Token 节约 **30%**
- ▶ 增效: 阻断错误尝试, 复杂 Bug 解决率 **+20-30%**
- ▶ 资产化: 消耗的算力转化为永久的企业私有资产 (可复用的项目活文档)。

我们构建的不是工具, 而是具备“经验记忆”的 **Autonomous Engineer**。

4. 业界实践与趋势：从向量到图谱的演进

主流产品记忆机制现状

- ▶ **ChatGPT**: 跨会话向量检索 (2025)。局限: 丢失关系链。
- ▶ **Claude**: 100K 超长上下文 + 知识库。
- ▶ **Gemini**: 1M tokens + Personal Intelligence (整合 Gmail/Photos)。
- ▶ 开源 (**LangChain/Auto-GPT**): 向量数据库。

核心痛点

向量 RAG 找“相似内容”，但不知因果关系，无法多跳推理。

Context Graph 新趋势

业界转向 **Graph-Enhanced Memory**:

- ▶ **Zep/Graphiti**: 时序知识图谱，记录事实演变。准确率 94.8%，延迟 -90%。
- ▶ **LangGraph**: 控制流图 (StateGraph)。
- ▶ **GraphRAG**: 社区检测 + 层级摘要。
- ▶ **Mem0**: 向量 + 图混合，速度 +91%。

趋势判断

被动检索 → 主动学习

- ▶ 主动总结经验 vs 被动挖掘知识
- ▶ 确定性推理 vs 概率匹配
- ▶ 知识迁移：解决未见过的问题